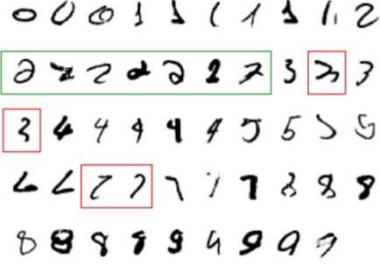
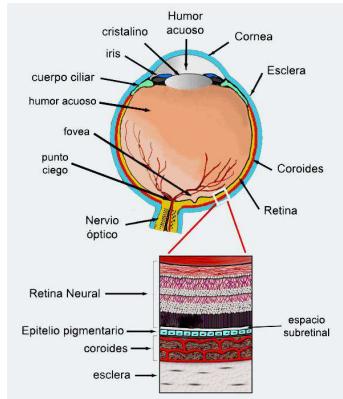


Super computadora humana



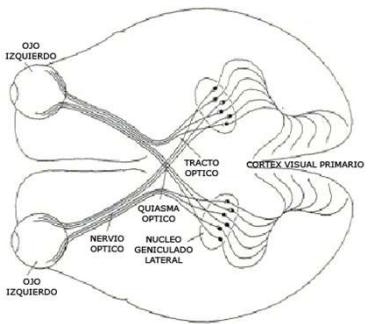


Detailed description: This diagram shows a cross-section of the human eye. Labels point to various parts: Cornea, Iris, Cristalino (lens), humor acuoso (aqueous humor), humor vitreus (vitreous humor), Retina, Optic nerve, Cuerpo ciliar (ciliary body), Fovea, Punto ciego (blind spot), Epitelio pigmentario (pigment epithelium), Coroides (choroid), and Esclera (sclera). A detailed inset at the bottom right shows the retina's layers: Retina Neural, Epitelio pigmentario, Coroides, and Esclera, along with the space between the retina and the choroid called espacio subretinal.

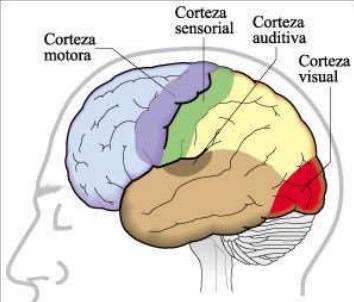
- La mayoría de las personas reconoce los dígitos 0 1 2 3 4 5 6 7 8 9
- Los humanos le dan sentido a los que ojos ven, pero casi todo el trabajo es procesado inconscientemente

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 3

Super computadora humana



Detailed description: This diagram illustrates the visual pathway. It starts with the 'OJO IZQUIERDO' (left eye) and 'OJO DERECHO' (right eye), which send optic nerves to the optic chiasm. The nasal fibers from each optic nerve merge at the optic chiasm to form the optic tracts. The optic tracts carry information to the lateral geniculate nuclei and the pretectal area. The optic radiations (geniculocalcarine tract) carry information to the occipital lobe, specifically to the 'Cortex Visual Primario' (Primary Visual Cortex).

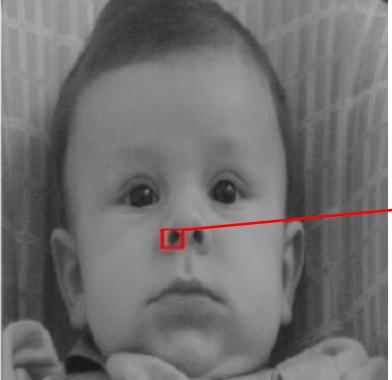


Detailed description: This diagram shows a lateral view of the human brain. It highlights several regions of the cerebral cortex: 'Corteza motora' (Motor cortex), 'Corteza sensorial' (Sensory cortex), 'Corteza auditiva' (Auditory cortex), and 'Corteza visual' (Visual cortex). The visual cortex is shown in red, indicating it is the primary visual area (V1).

- En cada hemisferio de nuestro cerebro, los humanos tienen una corteza visual primaria, también conocida como V1, que contiene 140 millones de neuronas, con decenas de miles de millones de conexiones entre ellas. Y, sin embargo, la visión humana implica no solo V1, sino toda una serie de corticales visuales (V2, V3, V4 y V5), haciendo una imagen progresivamente más compleja
- No solemos comprender totalmente cuán difícil es el problema que resuelven nuestros sistemas visuales!

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 4

Imagen Digital 2D



$f(x,y)$

99	71	61	51	49	40	35	53	86	99
93	74	53	56	48	46	48	72	85	102
101	69	57	53	54	52	64	82	88	101
107	82	64	63	59	60	81	90	93	100
114	93	76	69	72	85	85	94	95	99
117	106	94	82	97	101	100	108	105	99
116	114	109	106	105	108	108	102	107	110
115	113	109	114	111	111	113	108	111	115
110	113	111	109	106	108	108	110	120	122
103	107	106	108	109	114	120	124	124	132

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 5

Imagen Digital 2D



Una imagen...

	0.6	0.6	
0.6			0.6
0.6	0.6	0.6	0.6
0.6		0.6	

...es una matriz de pixeles.
El valor de los pixeles va de 0 a 255 pero se normaliza para la red neuronal de 0 a 1

Tamaño $6 \times 6 = 36$

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 6

Imagen Digital 2D

Si la imagen es a color, estará compuesta de tres canales: rojo, verde, azul.

Tamaño $6*6*3=36$

¿Cómo obtener características?

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 7

Filtros

- Matriz de coeficientes conocida **filtro, máscara o núcleo (kernel) de convolución**.
- Idea intuitiva:** se pasa el filtro en cada píxel de la imagen, aplicando los coeficientes según donde caigan.

Máscara de convolución con pesos W's

·1/4	·1/4
·1/4	·1/4

Aunque este filtro es par se utilizan Filtros impares- Simetría de la imagen

Imagen de entrada, A

92	78	82
45	80	130
39	115	154

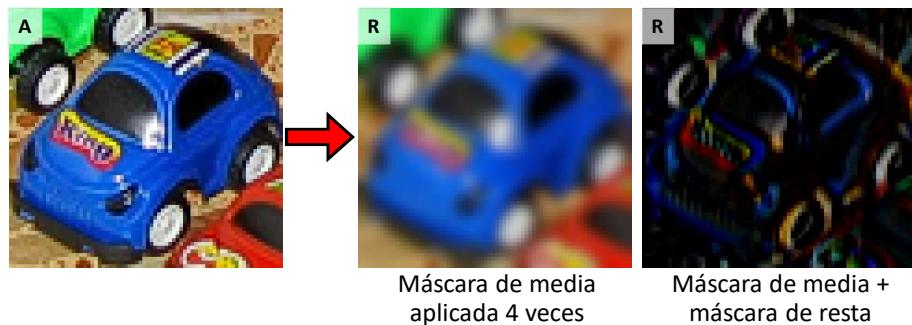
Σ

Imagen de salida, R

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 8

Filtros y convolución.

- Sobre una imagen se pueden aplicar **sucesivas operaciones de convolución**: ... $M_3 \otimes (M_2 \otimes (M_1 \otimes A))$



ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 9

Filtros y convolución - Efectos

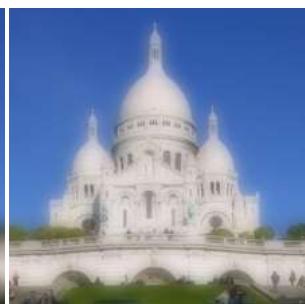
A. Imagen original



B. Suaviz. gauss. 40x40



Suma: 0,3A+0,7B



ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 10

Cambios de luminosidad

- Invariancia a cambios de luminosidad, color de la fuente de luz, etc.

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 11

Descomposición en diferentes patrones

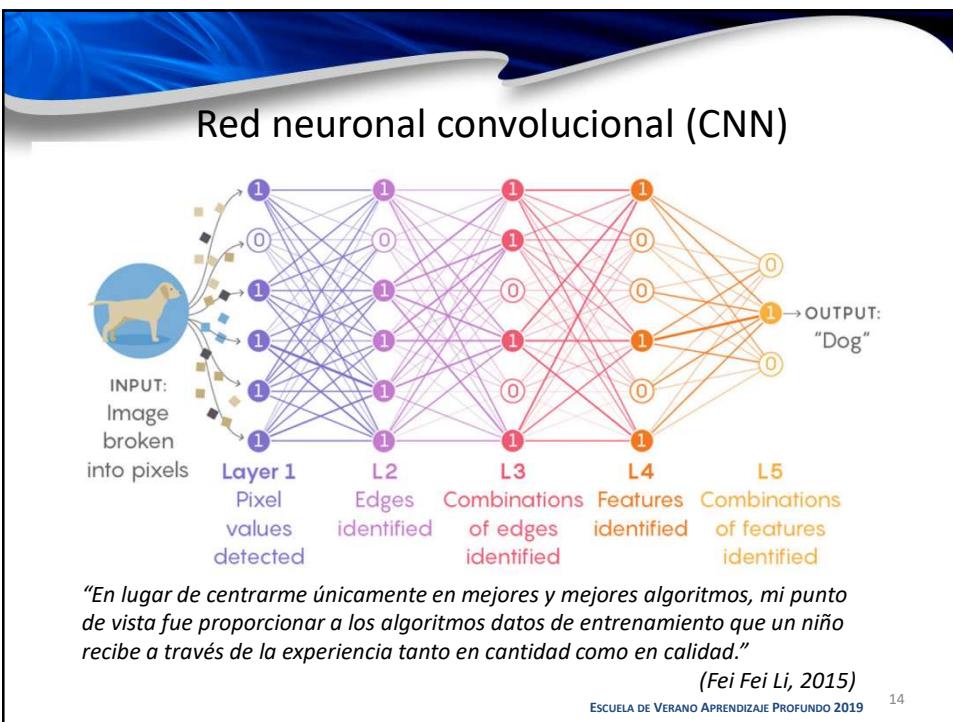
...para extraer características significativas!

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 12

- A los tres años, un niño ha visto cientos de millones de fotos del mundo real. Son muchos ejemplos de entrenamiento - Dígitos

Las redes neuronales convolucionales son diferentes. La idea es tomar la mayor cantidad de imágenes (dígitos) para su entrenamiento

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 13



Aplicaciones de CNN

The slide features three main sections:

- Classification:** Shows a single rabbit in a field. Below it is a diagram of a CNN architecture with the label "bunny".
- Detection:** Shows two yellow ducklings and one rabbit in a field, each highlighted by a red bounding box. Below it is a diagram of a CNN architecture with the labels "1: Duck, [x1, y1, x2, y2]", "2: Duck, [x1, y1, x2, y2]", and "3: Bunny, [x1, y1, x2, y2]".
- Segmentation:** Shows the same scene of two ducklings and one rabbit, but each animal is colored (orange, blue, black) to represent semantic segmentation. Below it is a diagram of a CNN architecture.

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 15

Aplicaciones de CNN

The slide features three main sections:

- Clasificación:** Shows a single rabbit in a field. Below it is a diagram of a CNN architecture with the label "bunny".
- Detección:** Shows two yellow ducklings and one rabbit in a field, each highlighted by a red bounding box. Below it is a diagram of a CNN architecture with the labels "1: Duck, [x1, y1, x2, y2]", "2: Duck, [x1, y1, x2, y2]", and "3: Bunny, [x1, y1, x2, y2]".
- Segmentación:** Shows the same scene of two ducklings and one rabbit, but each animal is colored (orange, blue, black) to represent semantic segmentation. Below it is a diagram of a CNN architecture.

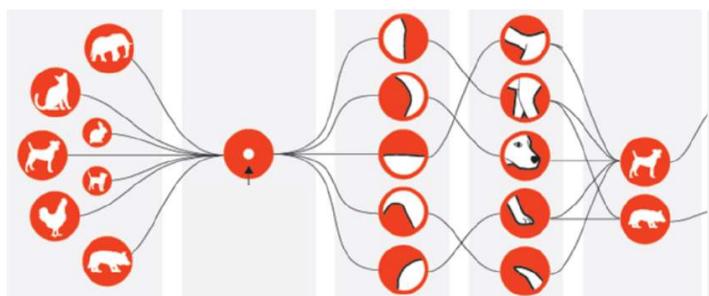
ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 16

Funcionamiento (CNN)

- CNNs son usadas para reconocer, detectar y segmentar objetos y escenas.
- Su uso se ha incrementado por 3 características importantes:
 - Eliminan la necesidad de extraer características (features) manualmente, éstas se aprenden directamente en la CNN.
 - Obtiene altos resultados de reconocimiento state-of-the-art.
 - CNNs se pueden reentrenar para nuevas tareas de reconocimiento, permitiendo el re-uso de redes preexistentes.

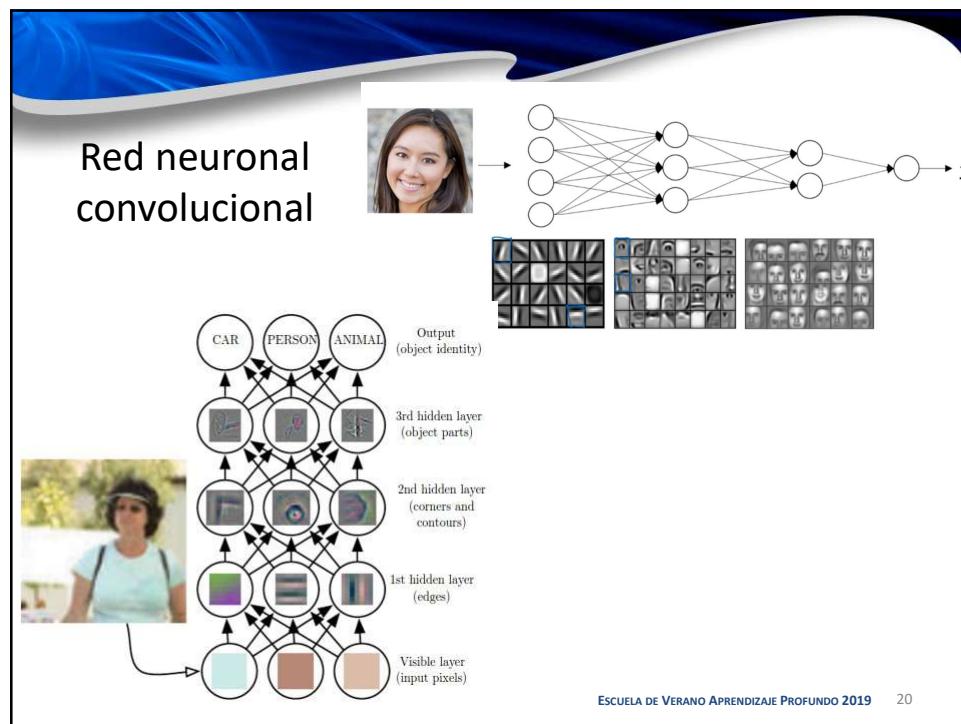
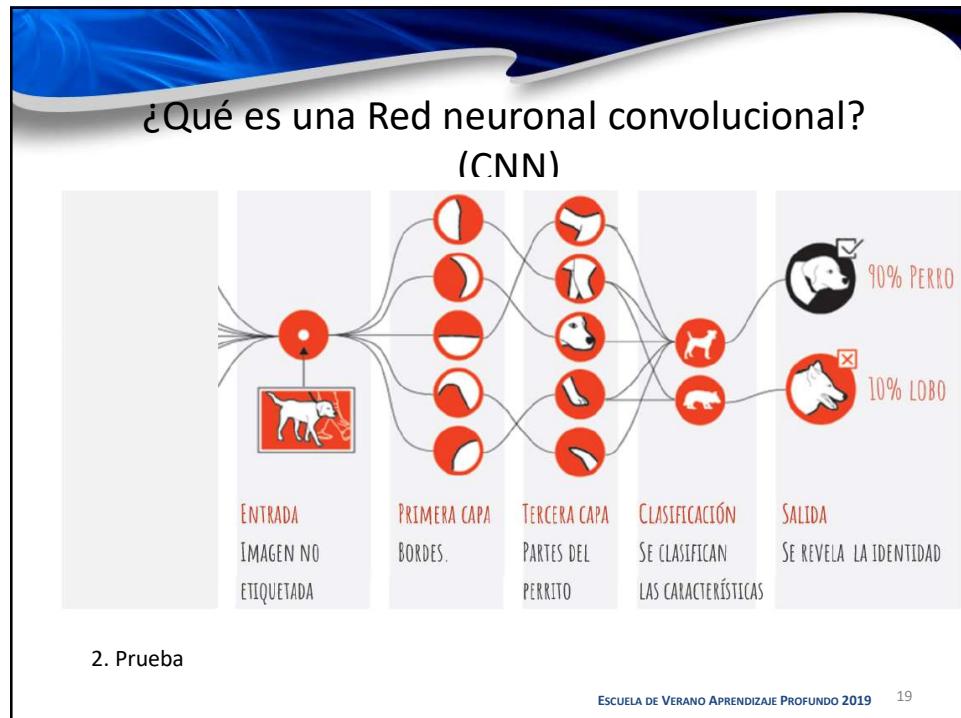
ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 17

¿Qué es una Red neuronal convolucional? (CNN)

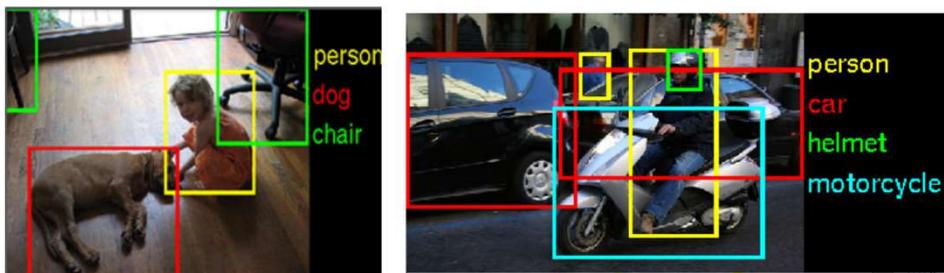


1. Entrenamiento

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 18



En imágenes

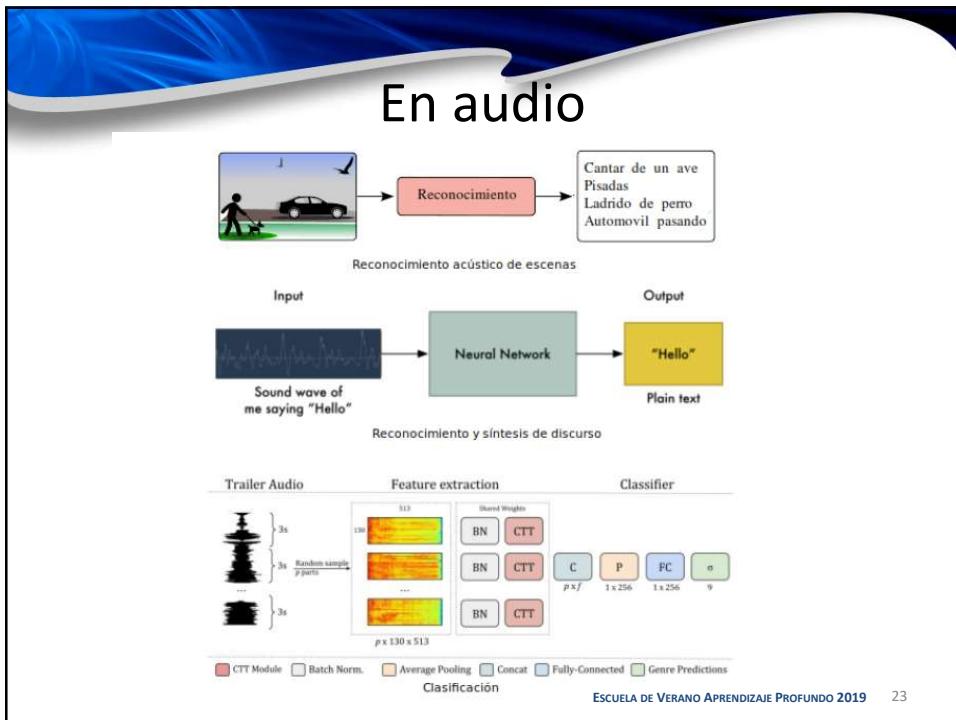


ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 21

En video



ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 22



¿Porque su rápida expansión?

The diagram is divided into three main sections by vertical dotted lines:

- Algorithms:** Shows a red circle containing the text "Algorithms". Below it is a diagram of an "Unsupervised pre-training" neural network with three layers of nodes, each with weights w_{ij} and bias b_i .
- Parallel computing:** Shows a blue circle containing the text "Parallel computing". It includes a diagram showing "CPU MULTIPLE CORES" represented by a stack of blue rectangles and "GPU THOUSANDS OF CORES" represented by a grid of small squares. Below this is an image of an NVIDIA TITAN Z GPU.
- Big Data:** Shows a purple circle containing the text "Big Data". It features a large image composed of many small, diverse photographs.

Below the diagrams, the text reads:

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 25

IMAGENET Large Scale Visual Recognition Challenge

Street drum

The Image Classification Challenge:

- 1,000 object classes
- 1,431,167 images

Output:

- Scale
- T-shirt
- Steel drum**
- Drumstick
- Mud turtle

A green checkmark is placed next to "Steel drum".

Output:

- Scale
- T-shirt
- Giant panda
- Drumstick
- Mud turtle

A red X is placed next to "Giant panda".

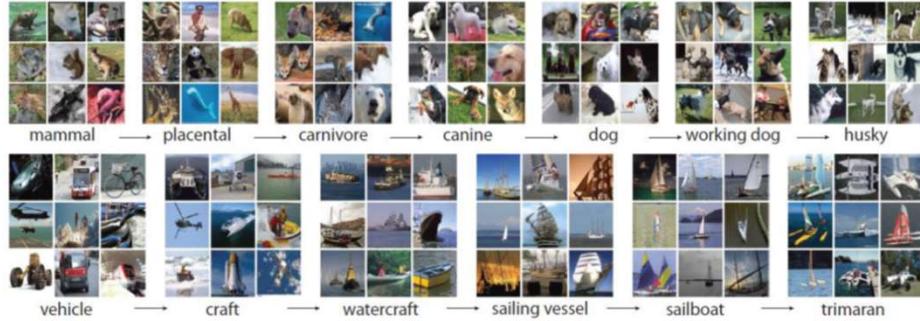
Russakovsky et al. arXiv, 2014

ImageNet Large Scale Visual Recognition Challenge (ILSVRC)

- Tarea1: Clasificación
- Tarea 2: Clasificación con localización
- Tarea 3: Clasificación Fina (Nueva)
 - En mas de 100+ categoría de perros.
 - Para cada categoría de perros predecir si el perro especificado dentro de una caja (bounding box) en la imagen de prueba es de una categoría particular

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 27

■ The ImageNet Large Scale Visual Recognition Challenge



1,461,406 imágenes de alta resolución

Múltiples anotaciones

Jerarquía de 100 clases de objetos en diferentes dimensiones

Competencia desde 2010

Los equipos de investigación evalúan sus algoritmos

[figures from www.nvidia.com]

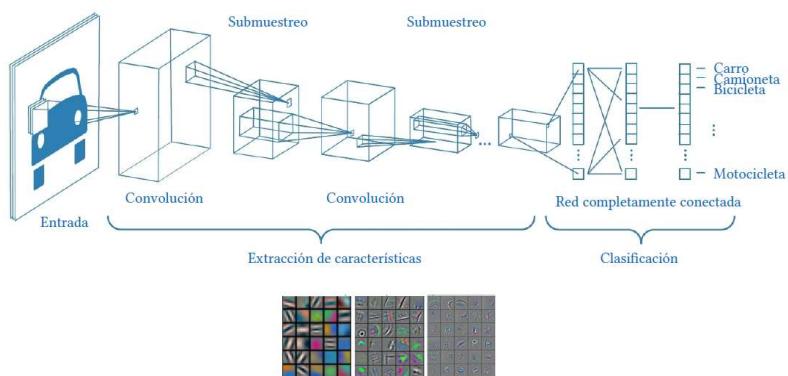
ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 28

Descanso!

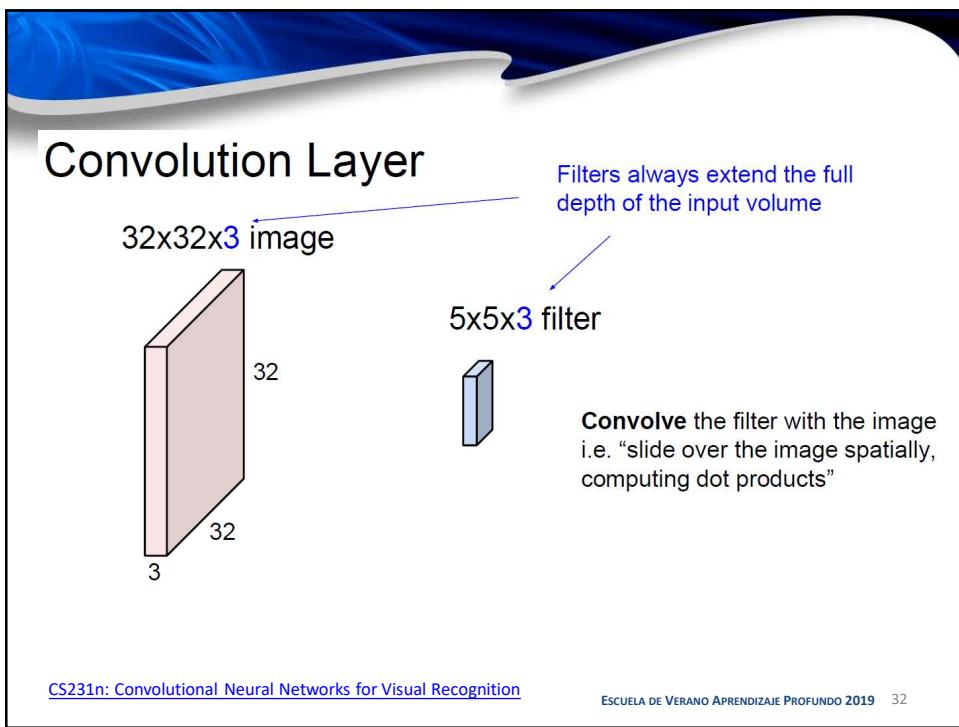
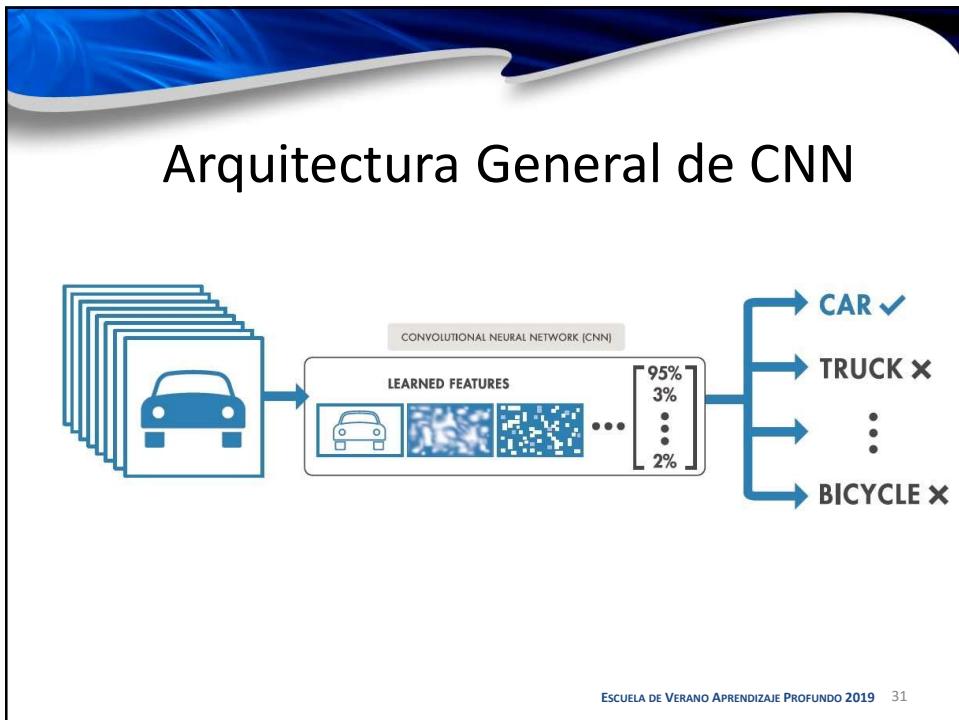


ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 29

Arquitectura General de CNN



ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 30



Convolution Layer

32x32x3 image
5x5x3 filter w

32
3

1 number:
the result of taking a dot product between the filter and a small 5x5x3 chunk of the image (i.e. $5 \times 5 \times 3 = 75$ -dimensional dot product + bias)
 $w^T x + b$

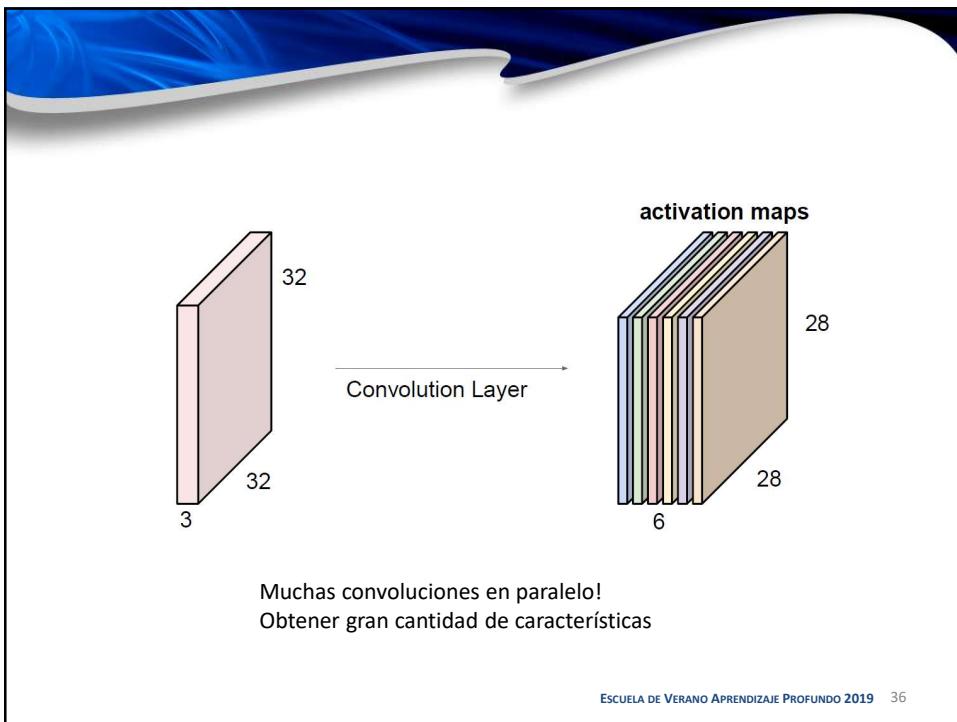
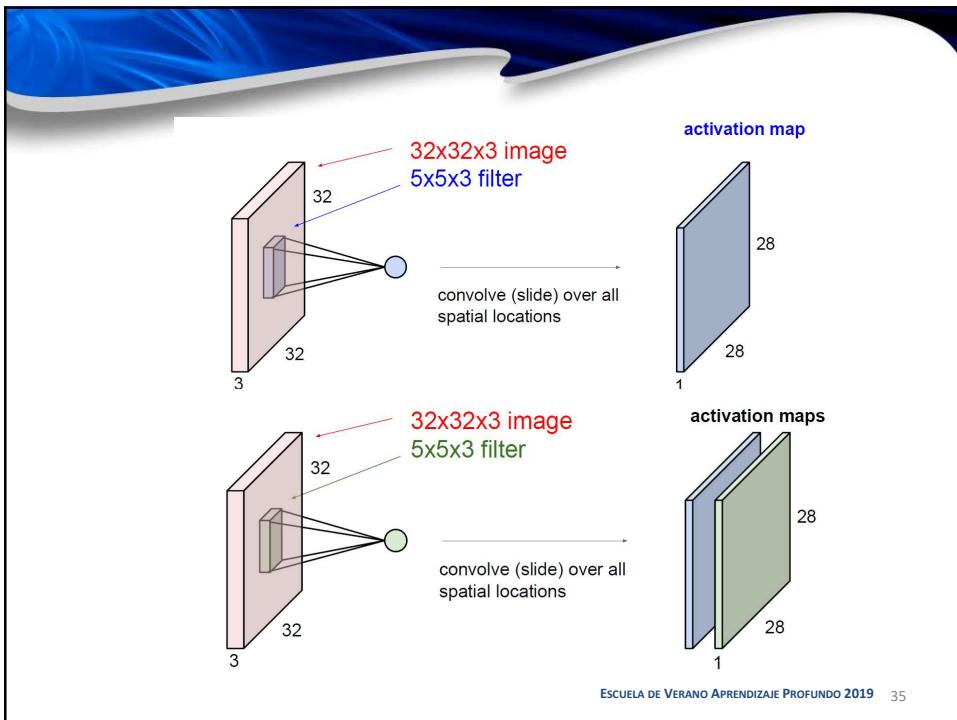
[CS231n: Convolutional Neural Networks for Visual Recognition](#)

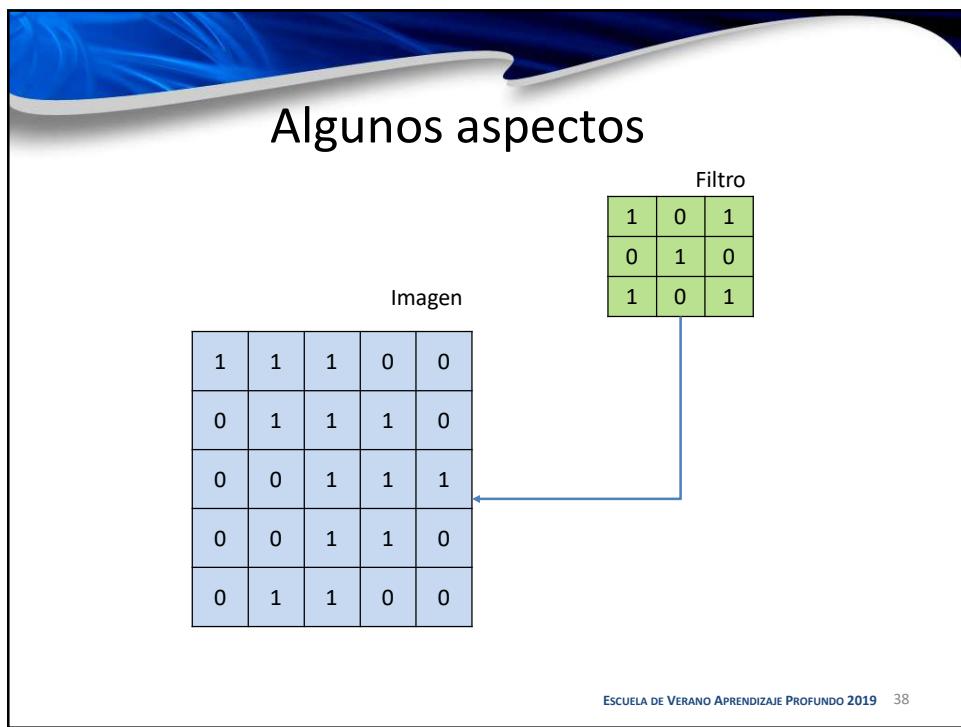
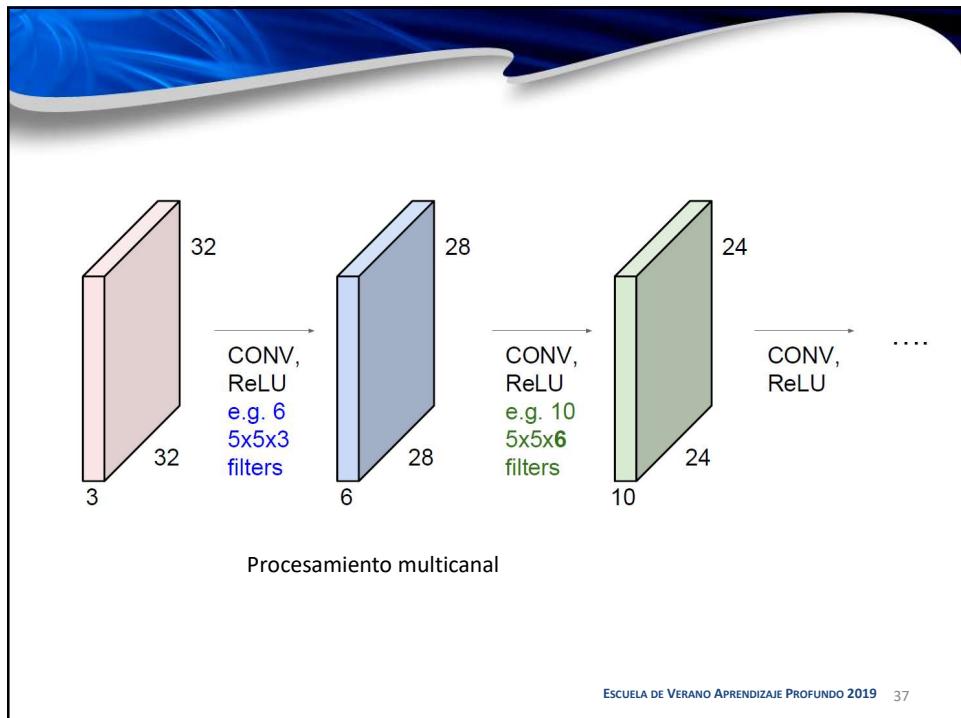
ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 33

Tamaño final de la operación

- $M-P+1$
- 7x7
- 3x3
- $7-3+1=5 \rightarrow 5 \times 5$

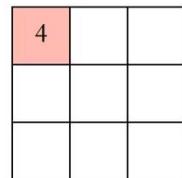
ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 34





Algunos aspectos- Paso (Stride)

1x1	1x0	1x1	0	0
0x0	1x1	1x0	1	0
0x1	0x0	1x1	1	1
0	0	1	1	0
0	1	1	0	0

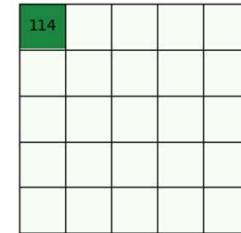


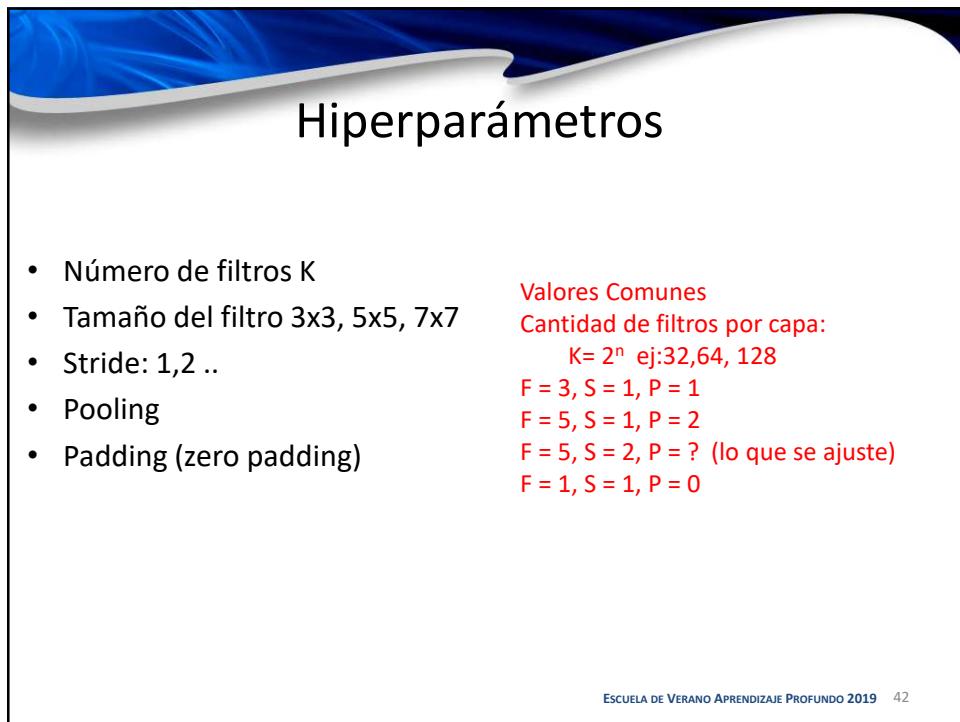
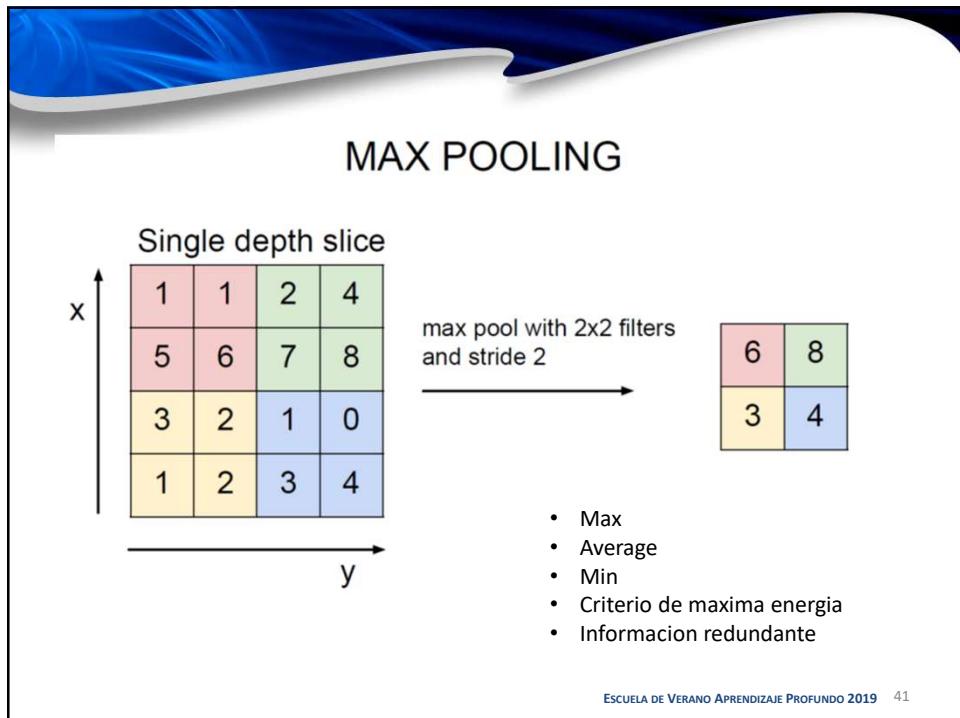
Reduce cálculo computacional

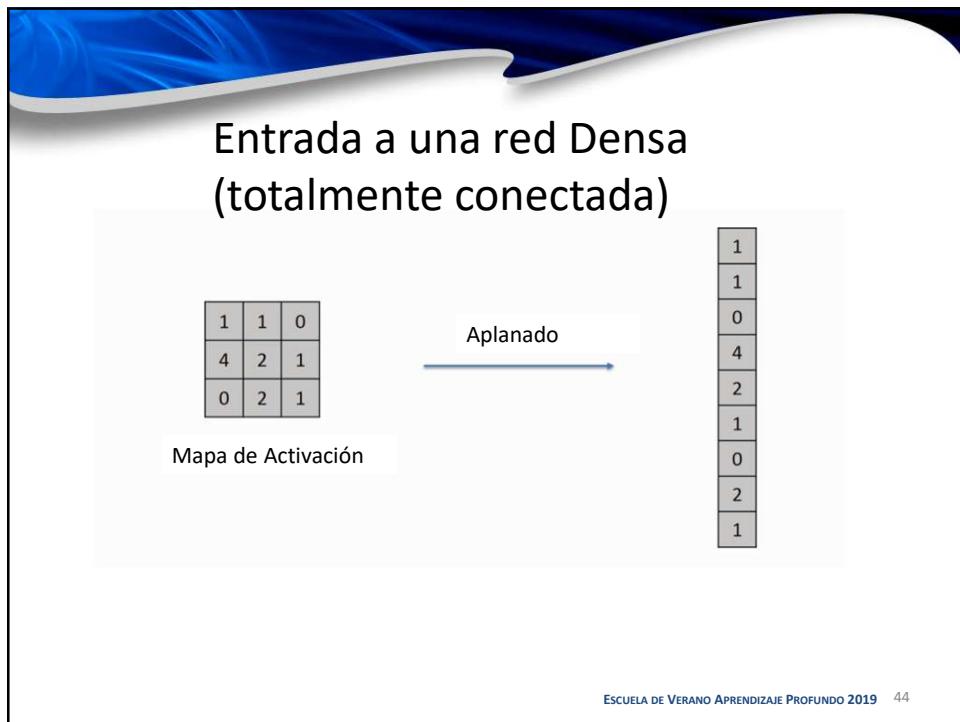
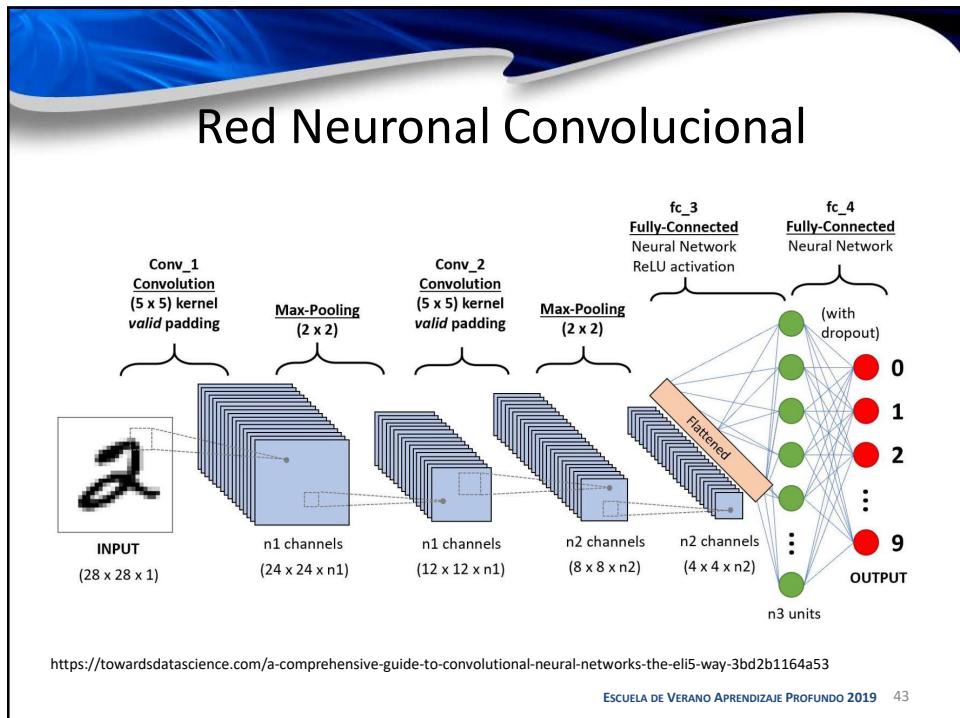
Zero Padding

0	0	0	0	0	0	0	0
0	60	113	56	139	85	0	0
0	73	121	54	84	128	0	0
0	131	99	70	129	127	0	0
0	80	57	115	69	134	0	0
0	104	126	123	95	130	0	0
0	0	0	0	0	0	0	0

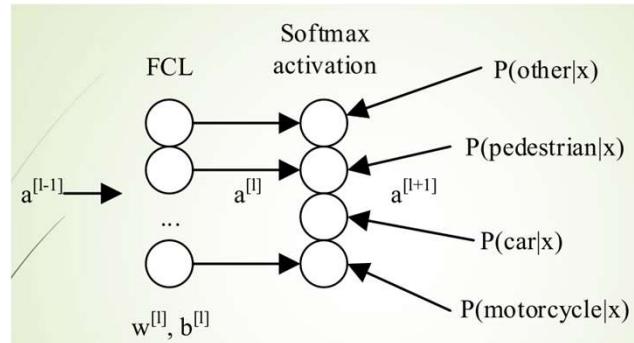
Kernel		
0	-1	0
-1	5	-1
0	-1	0







Por ejemplo: clasificador multicategórico (Softmax)

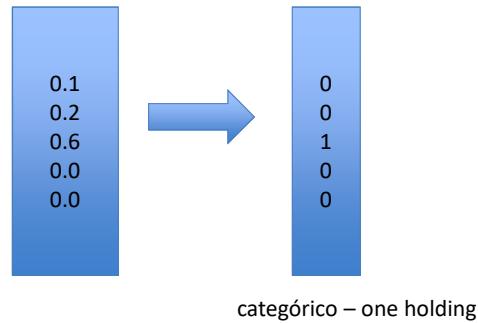


$$a^{[l]} = w^{[l]} a^{[l-1]} + b^{[l]}$$

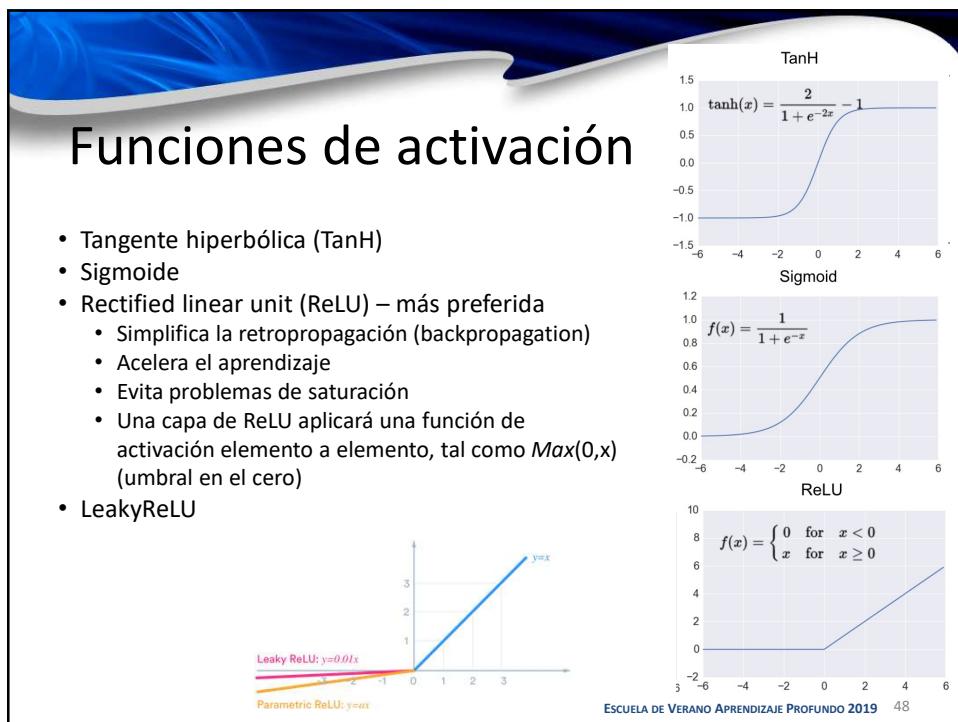
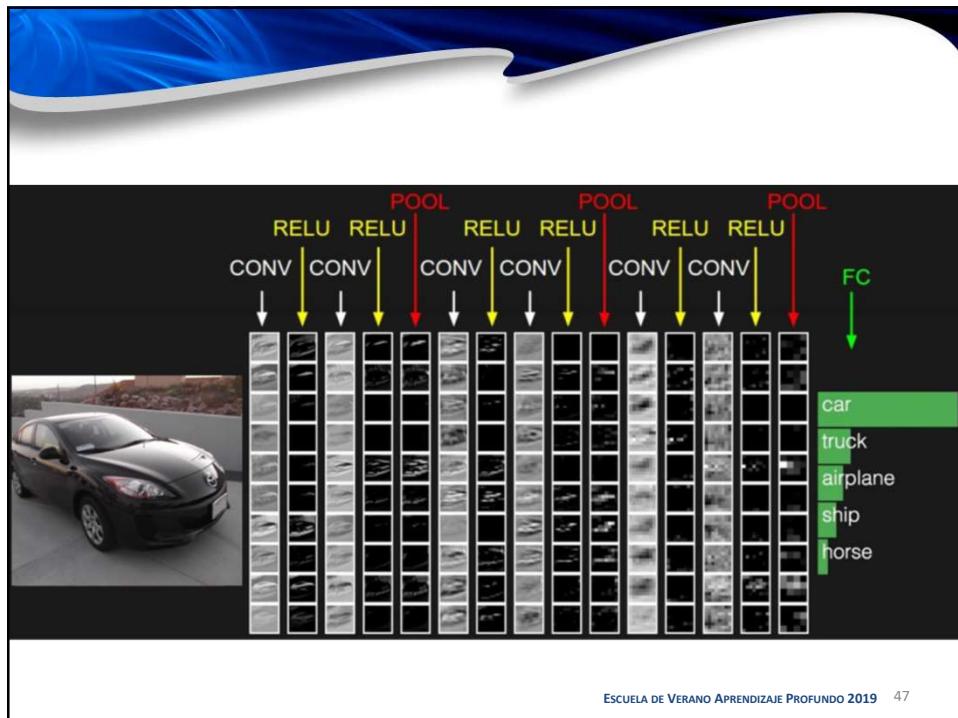
ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 45

Clasificador multicategórico (Softmax)

- Regresa un vector de probabilidades
- Tomando el valor máximo para la clasificación final.



ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 46



Entrenamiento lineal hacia adelante?

The diagram shows a stack of labeled photos on the left, divided into two categories: 'CAT' and 'DOG'. Each category has a stack of three labeled photos. To the right of the photos is a sequence of four vertical rectangles, each containing a grid of small black dots. These rectangles represent feature maps or hidden layers. An arrow points from the last rectangle to a horizontal line labeled 'OUTPUT'.

CAT
(LABELED PHOTOS)
DOG

OUTPUT

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 49

Entrenamiento en progreso

A diagram of a neural network with three layers. The input layer on the left has 784 nodes, indicated by a bracket below it. The middle layer has 25 nodes, and the output layer on the right has 10 nodes, labeled 0 through 9. Colored lines connect the nodes between layers, representing the weights of the connections. The background is dark.

784

0
1
2
3
4
5
6
7
8
9

3BLUE1BROWN SERIES- But what *is* a Neural Network?
https://www.youtube.com/watch?v=aircAruvnKk&list=PLZHQBObOWTQDNU6R1_67000Dx_ZCJB-3pi

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 50

Entrenamiento

(0.5 ↓ 0	○ 0
(0.8 ↓ 1	○ 1
(0.2 ↑ 2	● 2
(1.0 ↓ 3	○ 3
(0.4 ↓ 4	○ 4
(0.6 ↓ 5	○ 5
(1.0 ↓ 6	○ 6
(0.0 7	○ 7
(0.2 + 8	○ 8
(0.1 9	○ 9

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 51

Entrenamiento

Salida

Salida deseada

Average cost of all training data...

Cost of **2**

Error o "función de coste"

$$\left\{ \begin{array}{l} (0.71 - 0.00)^2 + \\ (0.49 - 0.00)^2 + \\ (0.67 - 1.00)^2 + \\ (0.02 - 0.00)^2 + \\ (0.27 - 0.00)^2 + \\ (0.62 - 0.00)^2 + \\ (0.05 - 0.00)^2 + \\ (0.88 - 0.00)^2 + \\ (0.14 - 0.00)^2 + \\ (0.90 - 0.00)^2 \end{array} \right.$$

Como hacemos para que el valor sea mas pequeño

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 52

Retropropagación

Gradiente descendente $W^{t+1} = W^t - \eta * \nabla(\text{función error})$

Backpropagation

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 53

Entrenamiento - Retropropagación

Backpropagation calculus

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 54

Parámetros en la retropropagación

Ecuacion de gradiente con la tasa de aprendizaje

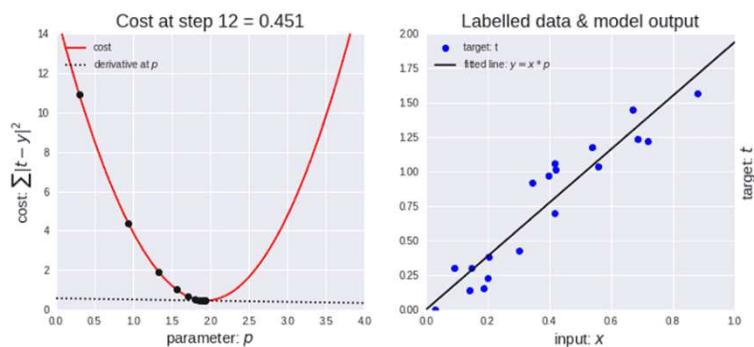
$$W^{t+1} = W^t - \eta * \nabla \alpha$$

$$\nabla \alpha = \left[\frac{\partial \alpha}{\partial W_1}, \frac{\partial \alpha}{\partial W_2}, \frac{\partial \alpha}{\partial W_3}, \dots \right]$$

- Tasa de aprendizaje $\eta = 0.001$ a 0.1

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 55

Función de Error (costo)



ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 56

Descenso del gradiente

- Encontrar el valor de los pesos W 's que hacen mínimo el error

$\theta := \theta - \nabla f$

$= \nabla f$
GRADIENTE

error

θ_0

θ_1

Tasa de aprendizaje: <http://www.benfrederickson.com/numerical-optimization/>

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 57

Funciones de pérdida

Error cuadrático medio
Tareas de regresión

$$E = \frac{1}{2} \sum_j (t_j - y_j)^2$$

Entropía cruzada binaria
Tareas de clasificación binaria.
Salida pasa por una sigmoidal entre 0 y 1

$$E = -\sum_j t_j \log y_j + (1-t_j) \log(1-y_j)$$

Entropía cruzada categórica
Tareas de clasificación multiclas.
Salida pasa a través de una softmax para que cada nodo de salida proporcione una probabilidad entre 0 y 1. Se usa con one hot encoders.

58

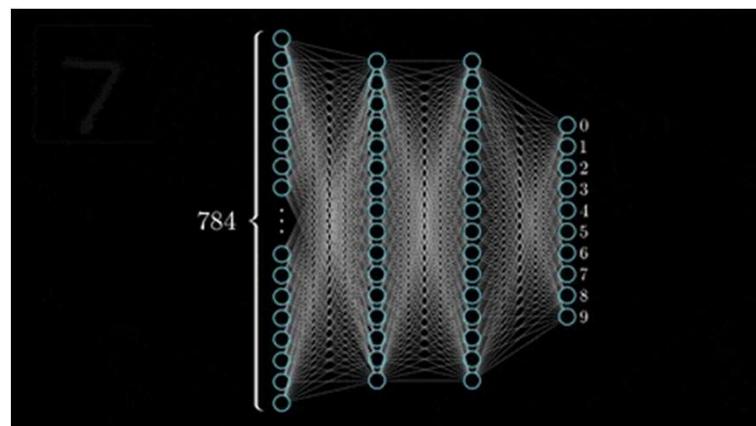
Optimizadores

Su principal objetivo es ir variando los parámetros para dar “el paso adecuado” y así llegar a un mínimo global de manera rápida.

- Descenso del gradiente estocástico - sgd
- Descenso del gradiente con momento - Acumula el gradiente de pasos previos para el siguiente avance (acelera).
- Propagación del la raíz promedio cuadrático – RMSprop, al elevar al cuadrado evita que se cancelen los gradientes
- Optimización adaptiva con momento - ADAM
- Otros: AdaDelta, SGD Nesterov, AdaGrad

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 59

Probar la Red convolucional



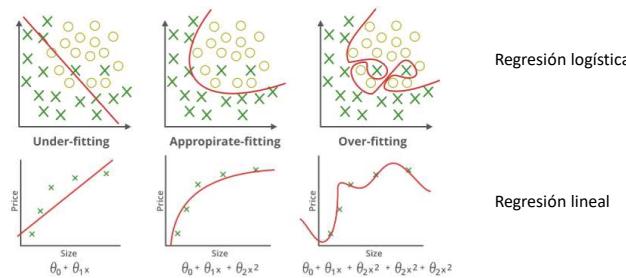
ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 60

Un problema muy común!

- Desvanecimiento del gradiente
 - Valores muy grandes en los filtros y otros demasiado pequeños, se tiene una divergencia de datos
- Sobre entrenamiento (overfitting), qué tan bien responde tu red a nuevos datos

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 61

Cómo evitar el sobreajuste (overfitting): regularización



Solución: agregar términos de regularización a la función de pérdida para reducir el número de parámetros o forzar que algunos de ellos sean cercanos a cero, o bien, eliminar nodos aleatoriamente (dropout)

$$E = \frac{1}{2} \sum_j (t_j - y_j)^2 + \frac{\lambda}{2} \sum_{i,j} w_{ji}^2$$

$$E = \frac{1}{2} \sum_j (t_j - y_j)^2 + \frac{\lambda}{2} \sum_{i,j} |w_{ji}|$$

$$E = \frac{1}{2} \sum_j (t_j - y_j)^2 + \frac{\lambda}{2} \sum_{i,j} \frac{w_{ji}^2 / w_0^2}{1 + w_{ji}^2 / w_0^2}$$

62

Entrenamiento por lotes (batches)

“Divide y vencerás”

- Se entrena a por secciones.
- Menos datos
- Más rápido

Mini-bach
Gradient descent

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 63

Ejemplo

- 2000 imágenes
- Batches =100 imágenes
- 20 pasos de cálculo de gradiente por época
- Número de épocas por ejemplo $epochs=100, 500, 1000\dots$

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 64

A programar!



LaPI
LABORATORIO AVANZADO DE PROCESAMIENTO DE IMÁGENES



CViCom

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 65

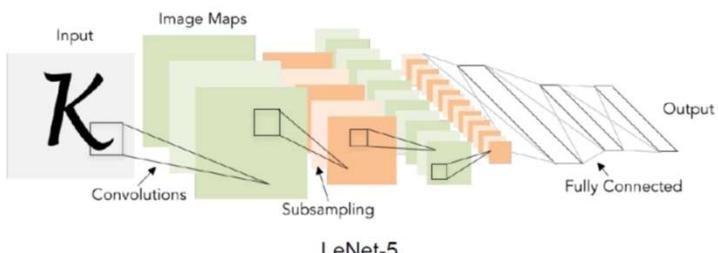
Arquitecturas Típicas

- AlexNet
 - Team Name: SuperVision
 - Team Member: Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton, University of Toronto
- VGG
 - Karen Simonyan, Andrew Zisserman, University of Oxford
 - Visual Geometry Group (Engineering Science)
- GoogLeNet
 - Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Drago Anguelov, Dumitru Erhan, Andrew Rabinovich
- ResNet

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 66

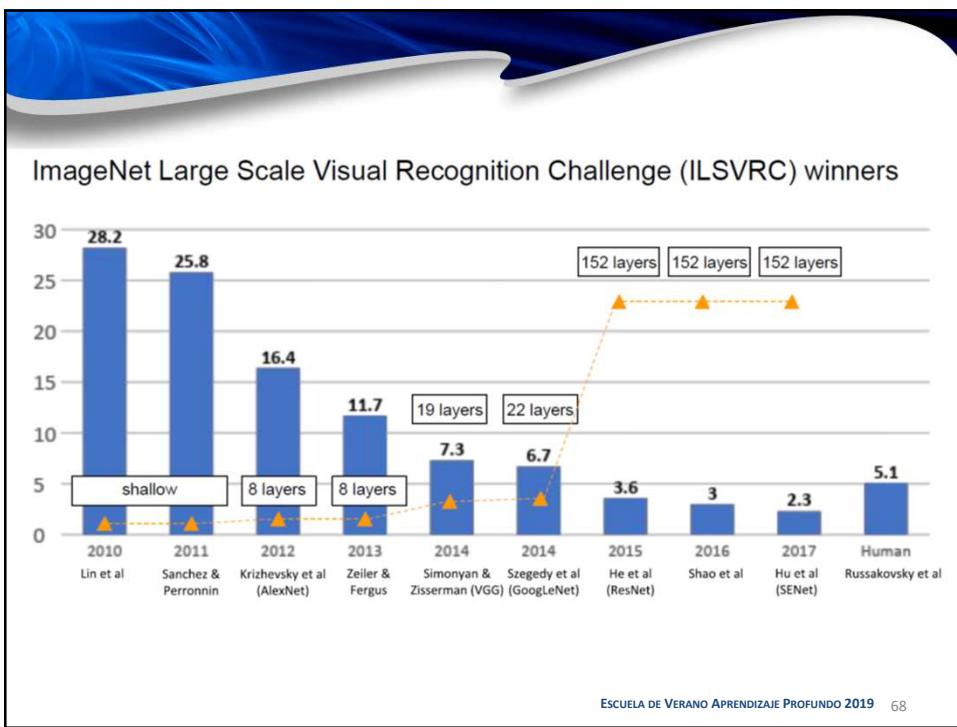
Un poco de historia..

Gradient-based learning applied to document recognition
[LeCun, Bottou, Bengio, Haffner 1998]



LeNet-5

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 67



Primeros que utilizan 2 GPUs en paralelo que comparten informacion entre ellos

ImageNet Classification with Deep Convolutional Neural Networks

[Krizhevsky, Sutskever, Hinton, 2012]

Figure copyright Alex Krizhevsky, Ilya Sutskever, and Geoffrey Hinton, 2012. Reproduced with permission.

“AlexNet”

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 69

ImageNet Classification with Deep Convolutional Neural Networks

[Krizhevsky, Sutskever, Hinton, 2012]

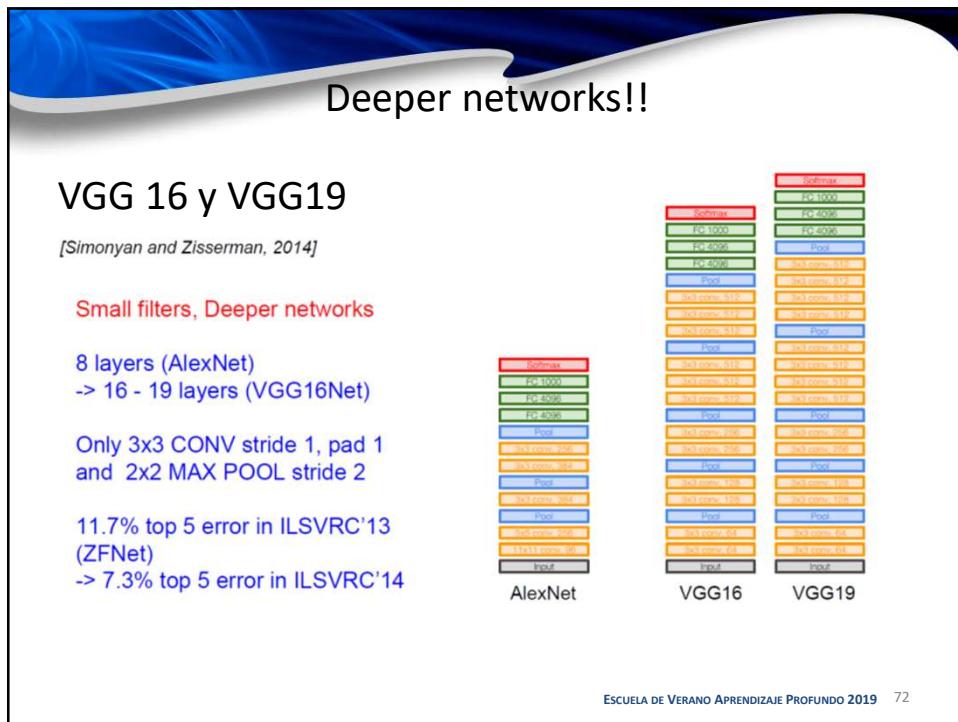
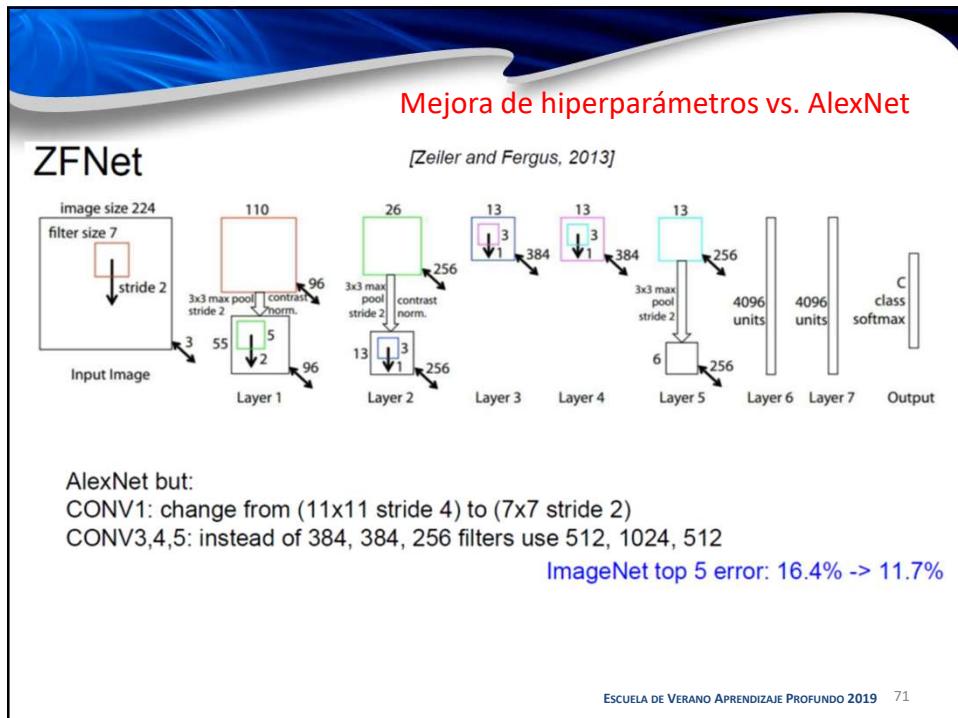
Arquitectura:

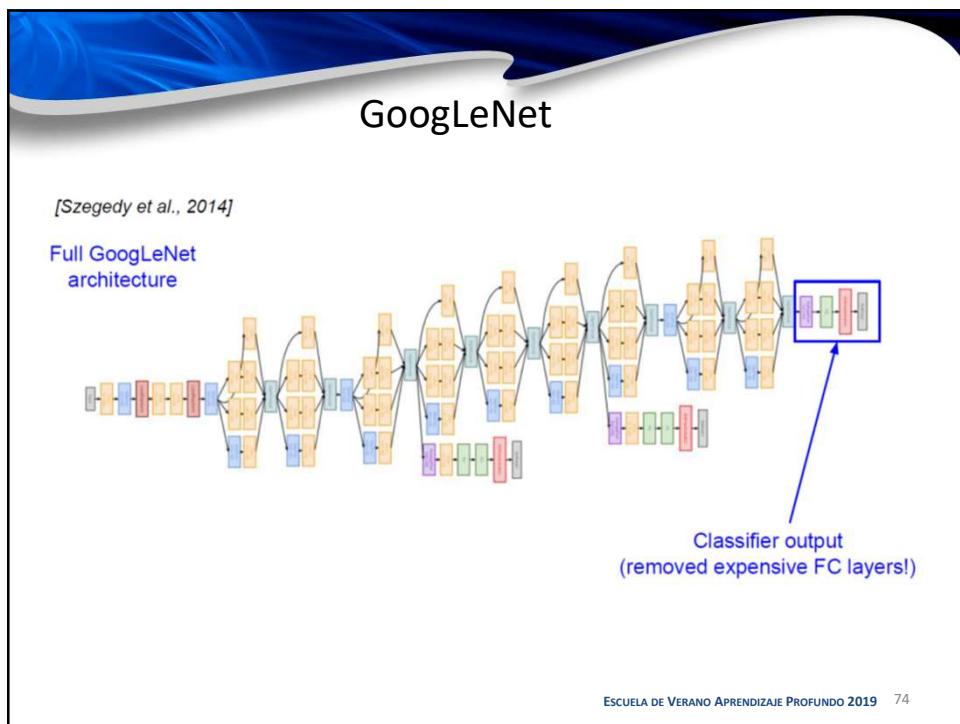
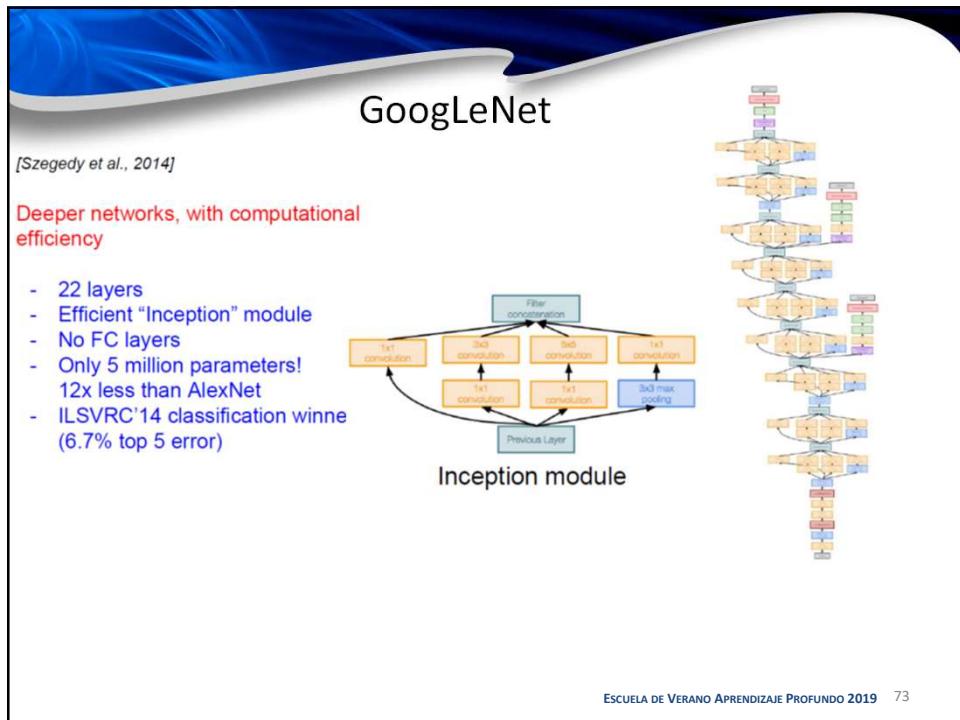
- [227x227x3] INPUT
- [55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0
- [27x27x96] MAX POOL1: 3x3 filters at stride 2
- [27x27x96] NORM1: Normalization layer
- [27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2
- [13x13x256] MAX POOL2: 3x3 filters at stride 2
- [13x13x256] NORM2: Normalization layer
- [13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1
- [13x13x384] CONV4: 384 3x3 filters at stride 1, pad 1
- [13x13x256] CONV5: 256 3x3 filters at stride 1, pad 1
- [6x6x256] MAX POOL3: 3x3 filters at stride 2
- [4096] FC6: 4096 neurons
- [4096] FC7: 4096 neurons
- [1000] FC8: 1000 neurons (class scores)

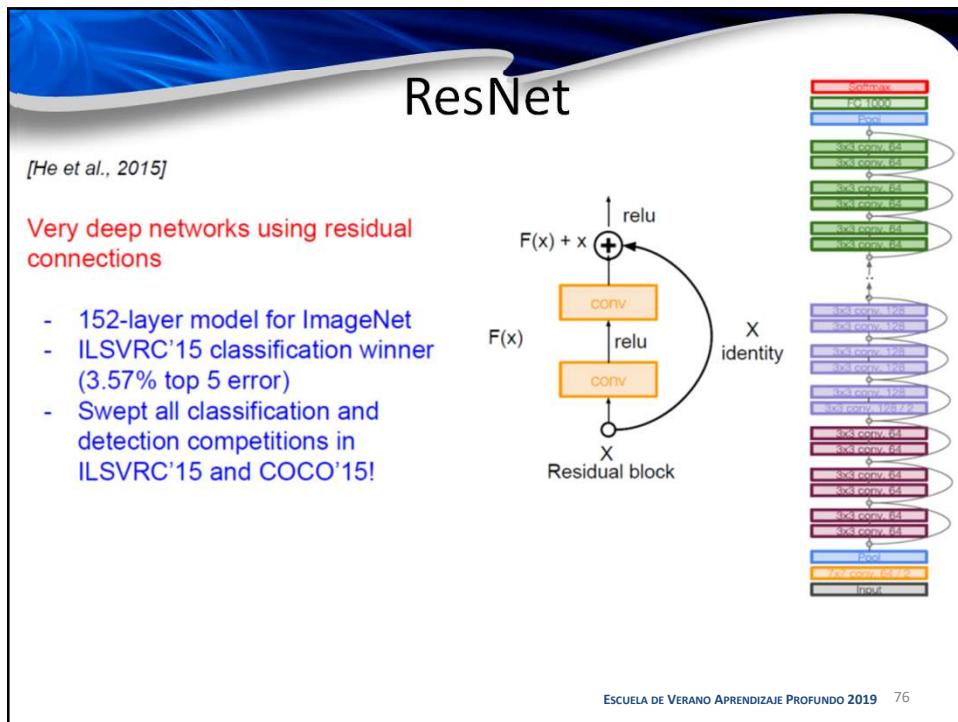
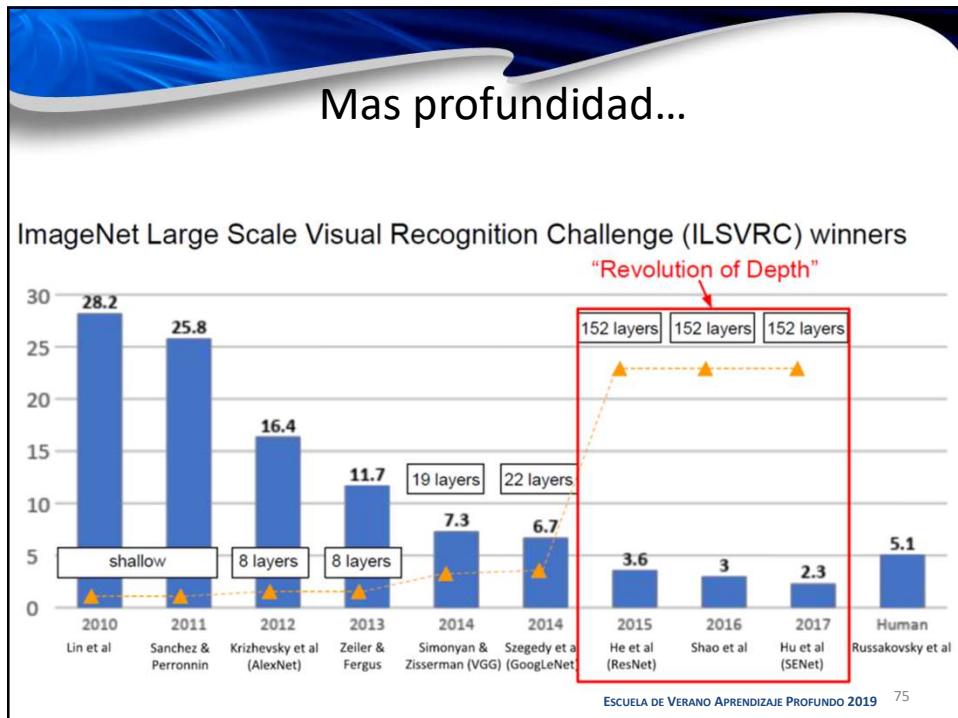
Figure copyright Alex Krizhevsky, Ilya Sutskever, and Geoffrey Hinton, 2012. Reproduced with permission.

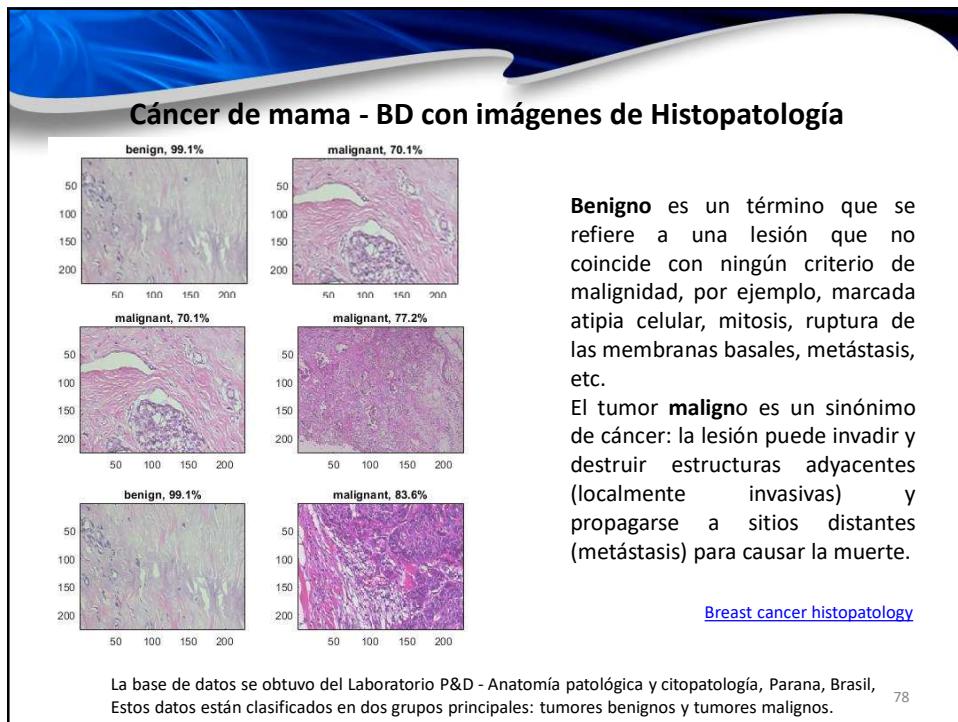
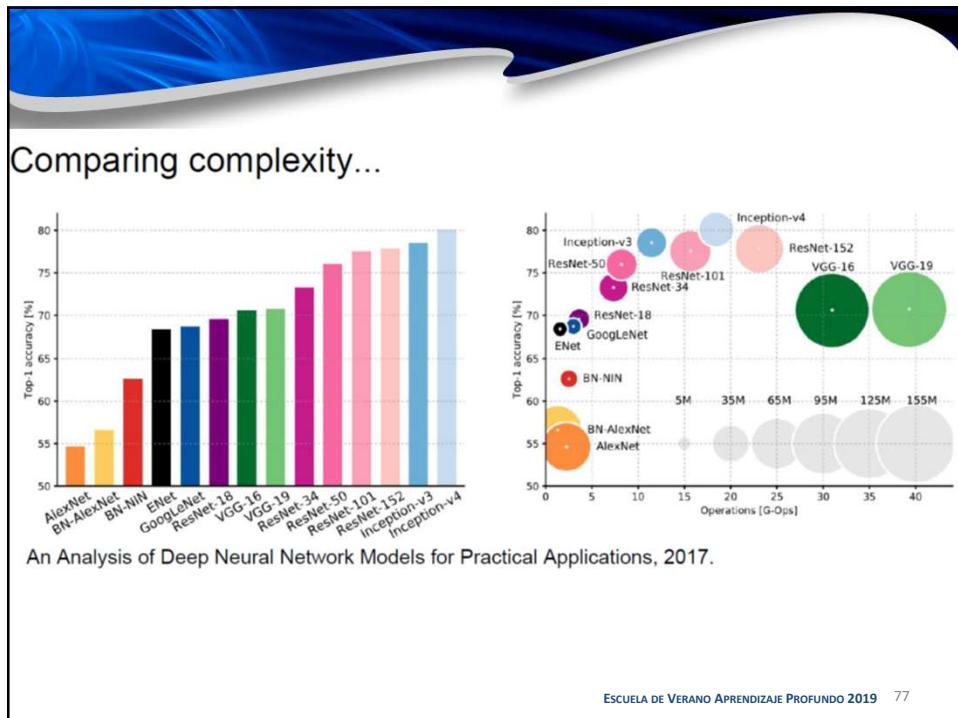
“AlexNet”

ESCUELA DE VERANO APRENDIZAJE PROFUNDO 2019 70









Cáncer de mama - BD con imágenes de Histopatología

P.J. Sudharshan et al./Expert Systems With Applications 117 (2019) 103–111

Table 2

Accuracy rate at respective levels. Best results columnwise are in bold. For statistical significance, please see text.

	Patient as bag				Image as bag			
	40×	100×	200×	400×	40×	100×	200×	400×
Iterated-discrim APR	73.8 ± 3.8	66.5 ± 4.1	84.2 ± 4.9	68.0 ± 5.6	70.4 ± 2.4	65.1 ± 5.0	81.3 ± 5.5	67.3 ± 4.9
DD	70.5 ± 6.1	64.5 ± 4.3	68.3 ± 3.6	71.2 ± 3.3	71.2 ± 5.9	66.1 ± 5.4	66.7 ± 2.9	70.8 ± 3.8
EM-DD	78.3 ± 5.6	80.6 ± 5.2	77.1 ± 6.3	78.7 ± 5.7	73.1 ± 5.4	76.4 ± 4.8	78.2 ± 5.2	76.2 ± 5.6
Citation-kNN	73.7 ± 4.6	72.8 ± 5.4	75.7 ± 3.1	77.2 ± 3.6	73.1 ± 4.3	73.0 ± 5.7	71.3 ± 3.5	78.7 ± 3.1
mi-SVM Linear	79.5 ± 4.3	83.4 ± 4.6	83.6 ± 4.7	81.0 ± 5.2	72.6 ± 4.4	80.6 ± 3.7	80.1 ± 4.9	78.2 ± 5.3
mi-SVM poly	75.2 ± 6.1	79.8 ± 4.8	76.5 ± 3.9	68.5 ± 5.1	75.6 ± 5.7	78.7 ± 4.0	75.2 ± 5.6	69.2 ± 4.8
mi-SVM RBF	77.8 ± 1.6	75.4 ± 1.5	73.8 ± 2.3	72.9 ± 3.4	77.9 ± 2.2	77.3 ± 2.1	74.6 ± 2.9	71.4 ± 3.9
Mi-SVM Linear	85.6 ± 5.6	82.1 ± 5.9	84.6 ± 4.8	80.9 ± 4.9	79.5 ± 4.1	78.2 ± 4.4	80.8 ± 4.7	78.9 ± 5.1
Mi-SVM poly	84.8 ± 2.7	82.5 ± 4.6	83.9 ± 4.2	81.3 ± 4.2	86.2 ± 2.8	82.8 ± 4.8	81.7 ± 4.4	82.7 ± 3.8
Mi-SVM RBF	79.0 ± 2.1	71.9 ± 2.9	76.2 ± 1.9	73.0 ± 3.5	78.3 ± 3.2	72.2 ± 3.0	76.8 ± 1.6	71.9 ± 2.4
Non-parametric	92.1 ± 5.9	89.1 ± 5.2	87.2 ± 4.3	82.7 ± 3.0	87.8 ± 5.6	85.6 ± 4.3	80.8 ± 2.8	82.9 ± 4.1
MILCNN	86.9 ± 5.4	85.7 ± 4.8	85.9 ± 3.9	83.4 ± 5.3	86.1 ± 4.2	83.8 ± 3.1	80.2 ± 2.6	80.6 ± 4.6